CAR-bench：GPT-6 Luna 消歧一致性实验

2026-10-19 · 原题 / 原工具环境 / 原评分逻辑 · 当前官方 test split

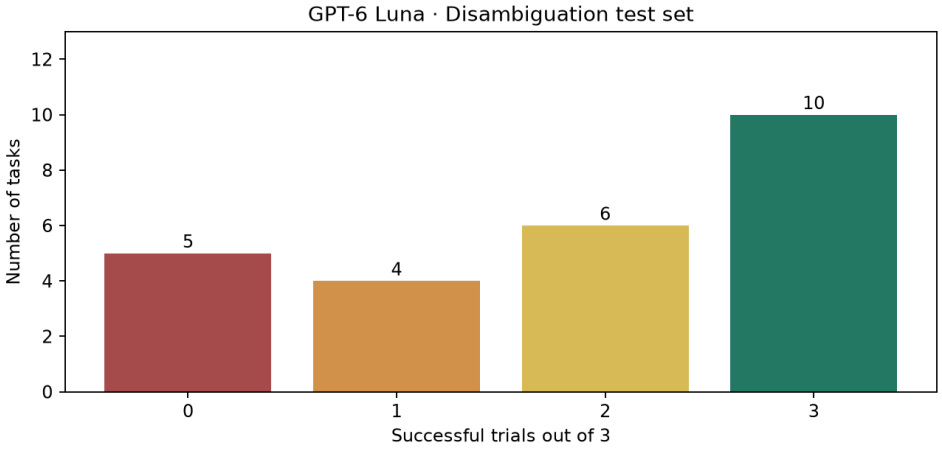
> 本次 25 题、75 次试验中，10 题三次全成功，10 题出现时成时败，5 题三次全失败。

运行审计：有 1 轮因本地费用账本文件锁中断，仅补跑该轮，未修改模型、题目或提示词。原始错误与替代轨迹保留在 infrastructure-errors；费用包含中断前已发生的调用。

主要结果

指标	结果	95% 区间
Pass@1：单次成功率	61.3%	46.7%–76.0%
Pass@3：三次至少成功一次	80.0%	60.9%–91.1%
Pass^3：三次全部成功	40.0%	23.4%–59.3%
一致性差距：Pass@3 − Pass^3	40.0%	23.4%–59.3%

Pass@3 与 Pass^3 的区间采用题目层面的 Wilson 区间；其他区间采用题目重采样 10,000 次。区间不涵盖模拟用户和评分器系统误差，也不代表整个真实世界任务分布。



两类消歧

作者题目标注	题数	Pass@3	Pass^3
查询环境/偏好自行消歧	13	76.9%	30.8%
向用户询问消歧	12	83.3%	50.0%

子组很小，属于描述性分析，不用于断言某类任务普遍更难。

论文结论在这里是否成立

- 一致性：本次差距为 40.0 个百分点。差距必须与成功率一起解读，稳定失败不等于可靠。
- 消歧可靠性：本次 Pass^3 为 40.0%，95% Wilson 区间为 23.4%–59.3%。论文 GPT-5 的 36% / 68%（Pass^3 / Pass@3）来自不同的原始评测范围，不能直接作为同样本显著性检验。
- 推理的因果效果：未设置 Luna reasoning=none 对照，不能据此判断开启推理带来多少提升。
- 幻觉与 Base 任务：本次未测，不能把 Disambiguation 的结果推广到论文其他结论。

历史同题参考：19 题

仅保留任务定义完全一致且历史记录无运行错误的题目。GPT-5 每题有 5 次历史试验，这里对全部 10 种三次组合求平均，计算与三次实验对应的指标。

指标	Luna 本次	GPT-5 历史	差值
Pass@1：单次成功率	64.9%	65.3%	-0.4 个百分点
Pass@3：三次至少成功一次	84.2%	85.8%	-1.6 个百分点
Pass^3：三次全部成功	42.1%	41.6%	+0.5 个百分点

这是历史参考，不是控制实验：代码、评分器版本、服务端模型及运行时间不同。即使任务定义一致，也不能把差值完全归因于 agent 模型升级。

三次全成功率差值的配对题目 bootstrap 95% 区间：-24.7 至 +24.2 个百分点。区间包含零，当前样本不足以支持稳定提升的结论。

失败类型与原始案例

下表按单次试验统计；一次失败可能涉及多个分项，不能相加当作总失败数。

评分分项	失败次数
最终状态不符	19
中间操作不符	16
缺少必要工具查询/动作	6
规则违反	15
工具调用错误	2
模拟用户判定消歧/对话失败	6

- **disambiguation_9，trial 1：**用户说“Can you turn on the beams?”，agent 直接问“Do you mean the low beams or the high beams?”，没有先查询环境。原题要求优先内部消歧，该轮被判 DISAMBIGUATION_ERROR；另外两轮成功。
- **disambiguation_29，trial 0：**在用户选择路线前已经修改导航并选取最快路线，随后才列出其他路线；同时没有按规则给出备选数量，出现动作和规则评分失败。
- **disambiguation_31，trial 0：**最终动作正确，但没有完整介绍备选路线，规则评分失败。完成主要任务与满足全部约束仍有区别。

这些案例是轨迹抽查，不是全量人工重标注。模拟用户本身也可能偏离脚本：例如 disambiguation_29 的脚本要求 agent 主动选路时结束对话，但该轮用户继续询问路线。保留官方评分，不人为修正分数；这也是解释结果时的限制。

成本和控制

供应商	Token 用量估算费用	控制
OpenAI	$0.102829	CAR-bench 独立项目月度硬上限 $10；本地 $9.50 提前停机
Gemini	$0.596416	本次程序本地 $4.50 提前停机，保留至 $5 的余量；不是 Google 账户级硬上限

合计约 **$0.6992**，包括连通性测试。按返回 token 与已核对单价估算，最终以平台账单为准。运行完成时没有未结算请求。

实验配置与限制

- Agent：gpt-6-luna，reasoning=medium，Responses API；不额外修改提示词，不添加搜索或其他外部工具。
- 模拟用户：gemini-2.5-flash，thinking=low（作者代码配置）；评分：gemini-2.5-flash，作者原始评分提示及逻辑。
- 每题独立启动 3 次，固定任务选择顺序 seed=769；未固定云端采样随机数。最多同时运行 3 道题。
- 每次调用输出上限 8,192 token，截断或基础设施错误触发停止，不当作模型答错。当前结果全部为正常完成的试验。
- 代码版本 `ce6dc9d08f4ff81eb4c1a5c317aff25112ee950b`；Hugging Face 数据版本 `1fcf24ad802c42e04a0d8fe05b5ca0d481a4e7af`。
- 采用当前官方代码，不是论文发布时的历史代码快照。任务定义审计发现 6 道 test 题相对历史记录发生变化。
- 仅三个重复，模拟用户和评分器也是随机模型；模型别名可能随服务更新变化。无独立人工标注全量复核。

检查原始证据

逐题结果 CSV · 指标与区间 JSON · 逐请求费用 · 失败项 · 历史题目差异 · 作者仓库

分享说明：原始证据链接指向私有 GitHub 仓库，组员需要仓库访问权限；本 PDF 可独立阅读。