CAR-bench：三类任务的成功率与一致性

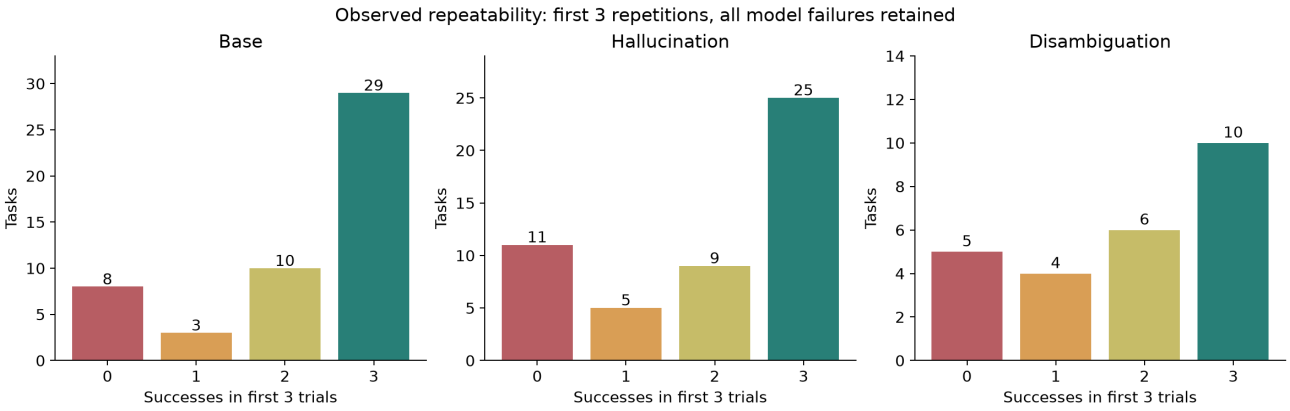
2026-10-19 • GPT-6 Luna medium • Gemini 2.5 Flash 模拟用户与评分 • 固定官方代码和数据版本

新增 Base 与 Hallucination 各 50 道 test 题；Disambiguation 沿用已完成的 25 题。主结果固定使用每题最先完成的 3 次重复，额外试验单独展示。预算中断不计为模型失败。

本次结果

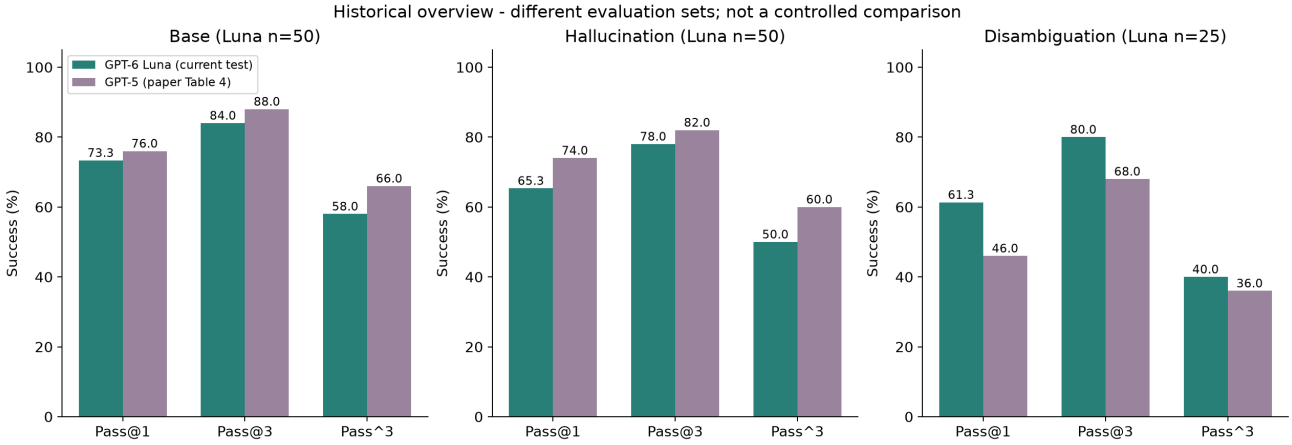
类别	完成三轮/全题数	全部有效试验	Pass@1	Pass@3	Pass^3	一致性差距
Base	50/50	341	73.3%	84.0%	58.0%	26.0 pp
Hallucination	50/50	343	65.3%	78.0%	50.0%	28.0 pp
Disambiguation	25/25	150	61.3%	80.0%	40.0%	40.0 pp

Pass@1 是单次成功率；Pass@3 是三次至少成功一次；Pass^3 是三次全部成功。差距为 Pass@3 Pass^3；稳定失败也会使差距变小，所以必须同时看成功率。



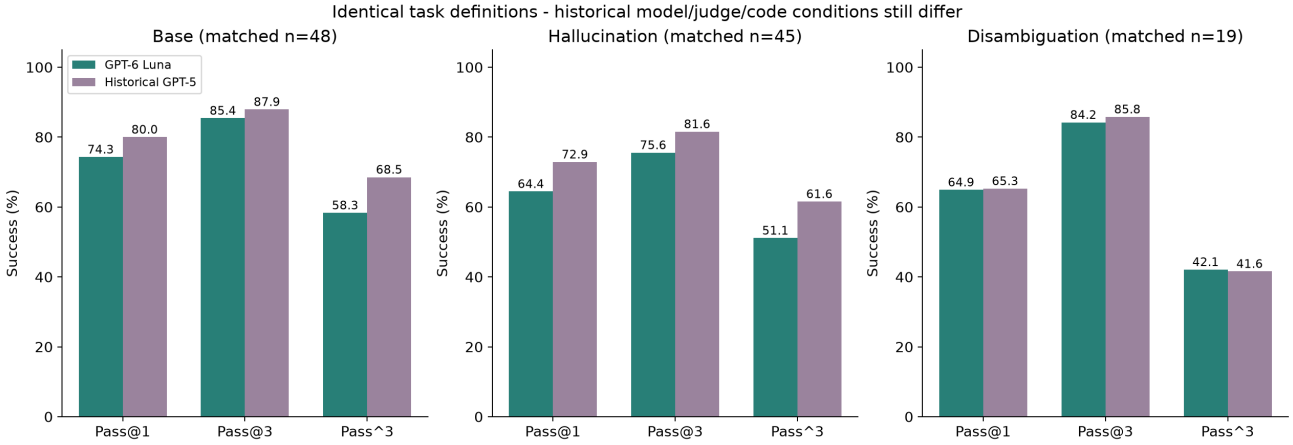
与论文原表比较：描述性概览

紫色为论文 Table 4 的 GPT-5 thinking 数值，绿色为本次当前 test split。评测题目范围不同，此图不能作为模型提升的因果证据。

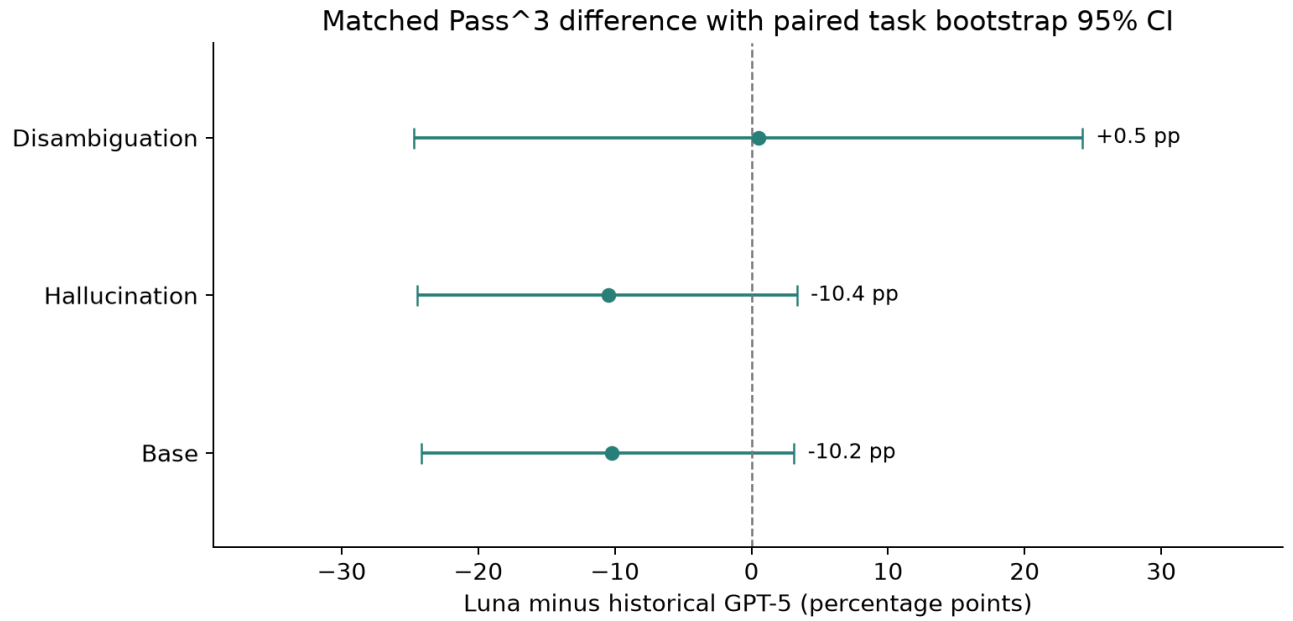


只比较题目定义相同的历史记录

逐题检查用户脚本、persona、环境配置、预期动作、缺失项和任务标注。仅保留所有历史重复定义均与当前一致、且没有运行错误的题。历史 GPT-5 的五次重复对全部三次组合取平均；Luna 使用预先指定的前三次。



类别	同题数	Luna Pass^3	GPT-5 Pass^3	差值	配对95%区间
Base	48	58.3%	68.5%	-10.2 pp	-24.2 至 +3.1 pp
Hallucination	45	51.1%	61.6%	-10.4 pp	-24.4 至 +3.3 pp
Disambiguation	19	42.1%	41.6%	+0.5 pp	-24.7 至 +24.2 pp



置信区间来自按题目配对重采样 10,000 次，不能消除历史代码、模型服务和评分器差异。区间跨零时，不支持方向明确的改善或退步结论。

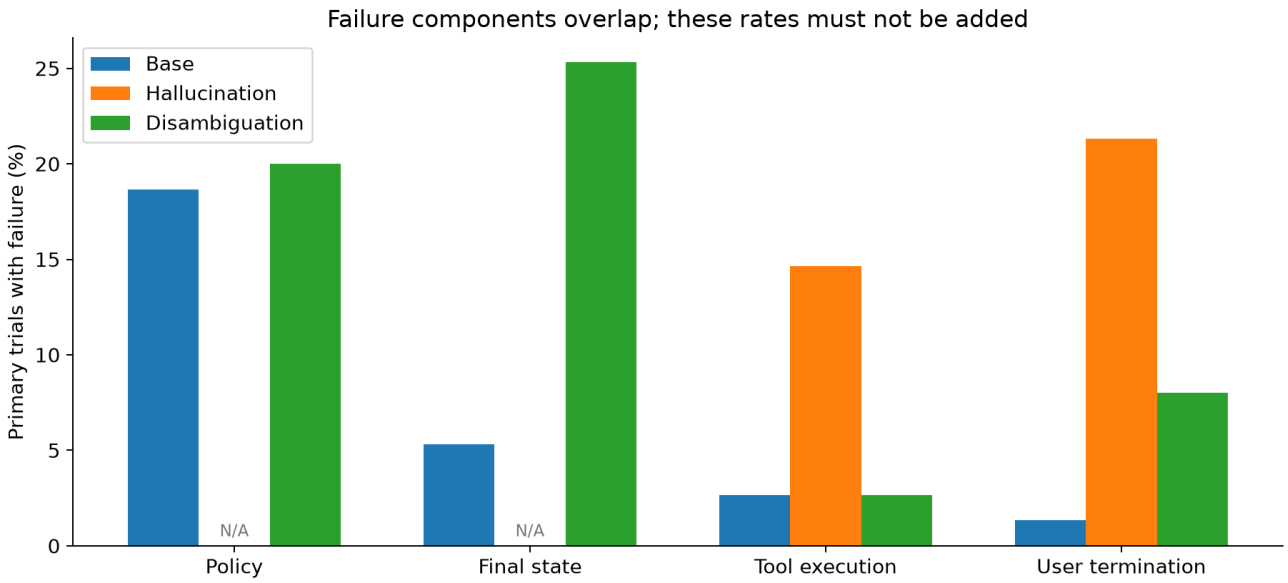
这些结果支持什么结论

• Base：前三轮的一致性差距为 26.0 个百分点。同题历史比较的差值区间跨零，当前样本未支持明确改善或下降。

• Hallucination：前三轮的一致性差距为 28.0 个百分点。同题历史比较的差值区间跨零，当前样本未支持明确改善或下降。

• Disambiguation：前三轮的一致性差距为 40.0 个百分点。同题历史比较的差值区间跨零，当前样本未支持明确改善或下降。

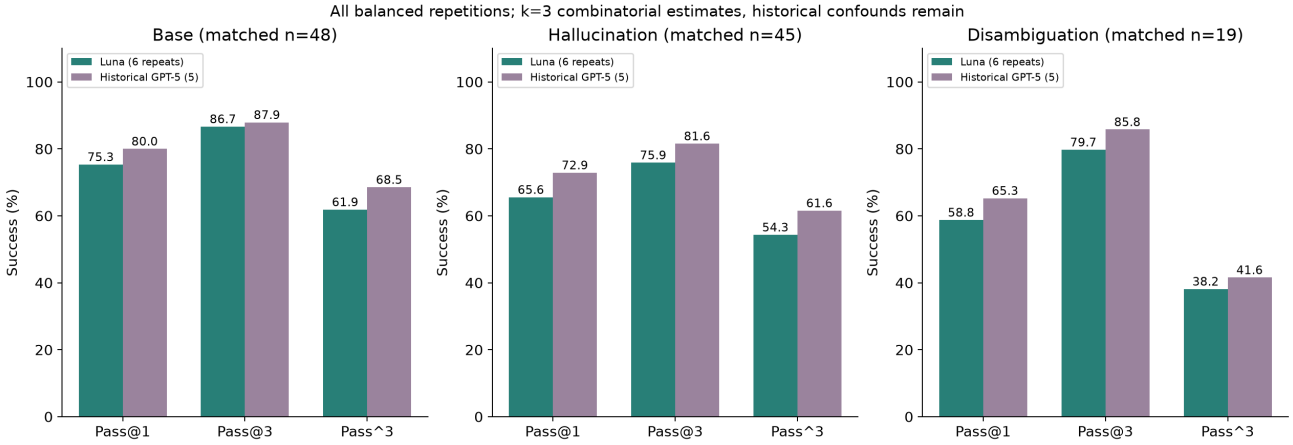
失败原因分布

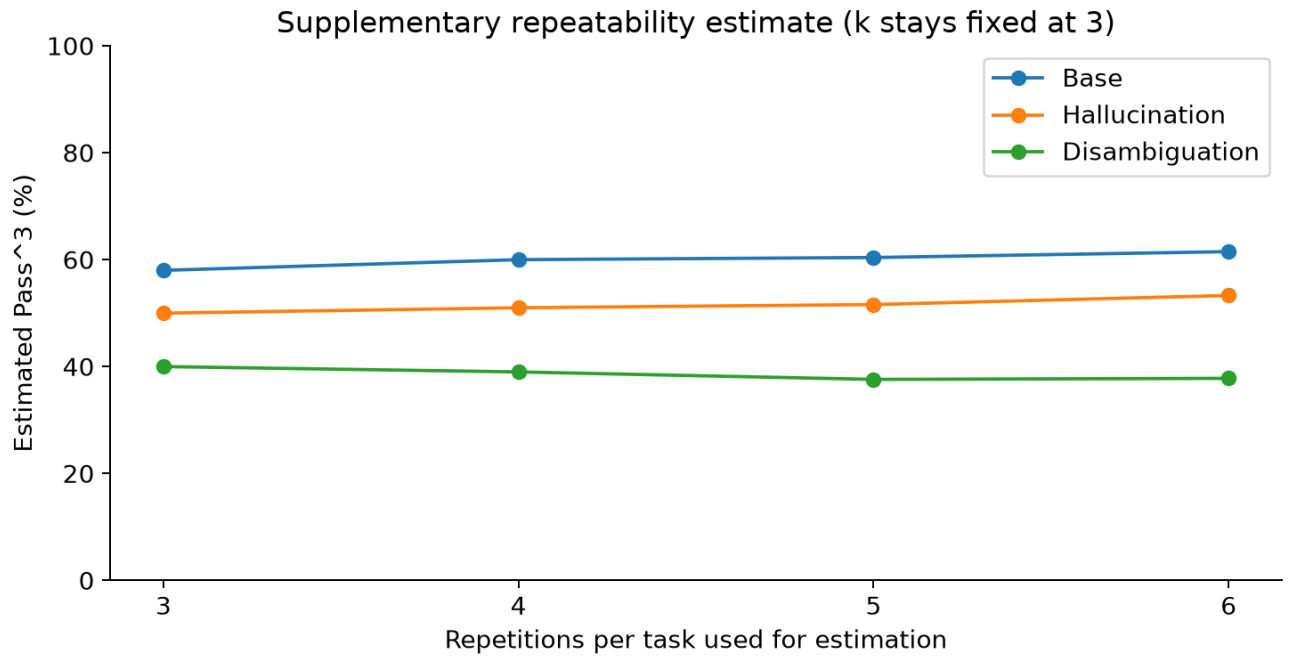


图中各分项可在同一次试验重叠，不能相加当作总失败率。官方代码跳过 Hallucination 的规则与状态目标评分，这两项标为 N/A，不表示零错误。模拟用户终止标记（例如 HALLUCINATION_ERROR、OUT_OF_SCOPE）单独保存在 summary.json 的 end_keywords 字段；它们属于模型评判结果，不是独立人工标注。

六轮对齐与补充重复

- Base：所有题共同完成 6 次重复。利用这些重复估计三次全成功率为 61.5%。
- Hallucination：所有题共同完成 6 次重复。利用这些重复估计三次全成功率为 53.3%。
- Disambiguation：所有题共同完成 6 次重复。利用这些重复估计三次全成功率为 37.8%。





- Base 的 48 道历史同题：使用前 6 次重复估计的 Pass^3 为 61.9%，历史 GPT-5 为 68.5%，差值 -6.7 pp，配对 95% 区间 -18.5 至 +4.7 pp。此项为补充分析，历史混杂限制同样适用。
- Hallucination 的 45 道历史同题：使用前 6 次重复估计的 Pass^3 为 54.3%，历史 GPT-5 为 61.6%，差值 -7.2 pp，配对 95% 区间 -19.0 至 +3.8 pp。此项为补充分析，历史混杂限制同样适用。
- Disambiguation 的 19 道历史同题：使用前 6 次重复估计的 Pass^3 为 38.2%，历史 GPT-5 为 41.6%，差值 -3.4 pp，配对 95% 区间 -26.3 至 +17.4 pp。此项为补充分析，历史混杂限制同样适用。

类别	共同完整轮次 n	n 次全部成功（不可直接与历史五轮比较）
Base	6	54.0%
Hallucination	6	44.0%
Disambiguation	6	32.0%

额外试验按固定顺序均衡推进，未根据是否成功选择重跑。Base 和 Hallucination 在用户要求下停止第七轮，保留部分第七轮数据；Disambiguation 随后仅补至第六轮，或在预算保护触发时停止。不同题额外完成次数可能因此不一致；主结果始终保留前三次，补充结果只使用所有题共同完成的前 n 次，按组合公式估计 k=3 指标：对 n 次中成功 c 次的题，Pass^3 = C(c,3)/C(n,3)，Pass@3 = 1 C(n c,3)/C(n,3)，再对题目等权平均。

费用及停止原因

含前次消歧实验的累计估算：OpenAI $0.930797，Gemini $4.989678，合计 $5.920475。仍在进行的请求预留数：0；有 3 次服务异常或进程中断没有返回用量，已按 $0.078386 保守预留计入上述费用。本地提前停机线为 OpenAI $9.50、Gemini 充值授权后 $9.50（此前 $4.50；补跑开始时 $4.98），OpenAI 仍受 $10 总预算约束；Gemini 原预算 $5，用户随后追加 NZ$10，本地仅增加按 US$5 计算的额度并保留余量。

Base 与 Hallucination 保留六轮及部分第七轮，按用户要求停止追加。Disambiguation 在追加充值授权后补至六轮并停止。运行期间的预算保护、服务错误、受控重启及费用预留详见 events.jsonl 和 usage-ledger.json。

解释范围

• 运行中出现 Gemini 503 服务错误。保留已完成结果，恢复被中断的试验；随后将 Gemini 同时请求限制为 2，并对临时服务错误最多尝试 3 次、间隔 20/40 秒。每个失败请求仍保留最大费用预留。另外曾出现 Gemini 输出截断，之后仅对截断的 Gemini 请求允许 16,384 token 上限重试，正常请求仍为 8,192；Luna 上限保持 8,192。每次尝试单独计费并保留记录，模型、任务和评分提示未改变。

• 本次只替换被测模型，使用当前官方任务、工具与评分代码；这不是对论文历史环境的逐字重建。

• Hallucination 任务考察能否识别并说明缺失工具或信息，评分也受无效工具调用和偏离任务影响，失败率不等同于直接观察到的编造率；需结合轨迹和失败分项解释。

• 三类题目的难度和构成不同，类别分数差异不能单独证明某种能力的因果影响。

• 未增加 reasoning=none 对照，不能归因于推理开关。服务端随机性与模拟用户/评分器误差仍存在。

证据与下载

逐题结果 • 完整指标 • 题目差异审计 • 累计费用 • 作者仓库

价格来源：OpenAI / Google。费用由返回 token 估算，最终以供应商账单为准。PNG 与 SVG 图表和原始试验文件随复现资料保存。

复现仓库（私有，需访问权限）：github.com/victorcao1104/car-bench-gpt6-luna-reproduction

完整可点击证据链接保留在随附 HTML 报告中。作者仓库：github.com/CAR-bench/car-bench